

Rapport – Projet Machine Learning (Prédiction du défaut de prêt)

1. Compréhension de la problématique

Le projet traite d'un problème de classification supervisée visant à prédire le risque de défaut de remboursement d'un prêt bancaire.

Objectif métier : déterminer si un client va rembourser son prêt ou entrer en défaut de paiement.

Variable cible : Status (0 = remboursé, 1 = défaut).

Type : classification binaire.

Objectifs : automatiser l'évaluation du risque crédit, améliorer la prise de décision bancaire, réduire les pertes financières.

2. Analyse exploratoire des données (EDA)

2.1 Structure du dataset

148 670 observations, 34 variables.

2.2 Variable cible

Classe 0 (~75%), Classe 1 (~25%) → dataset déséquilibré.

2.3 Types de variables

Variables numériques et catégorielles (revenu, loan_amount, region, loan_type, etc.).

2.4 Valeurs manquantes

Présentes dans rate_of_interest, income, property_value, LTV, dtir1.

2.5 Observations

Présence d'outliers et forte variabilité des montants et revenus.

2.6 Variables influentes

Catégorielles : credit_type, loan_type, region.

Numériques : dtir1, income, LTV, loan_amount.

3. Prétraitement des données

- Encodage One-Hot des variables catégorielles
- Imputation médiane pour numériques
- Imputation mode pour catégorielles
- Standardisation des variables numériques
- Analyse de corrélation pour multicollinéarité

4. Construction des modèles ML

Modèles testés : Logistic Regression, Random Forest, Gradient Boosting.
Utilisation de pipelines avec preprocessing et validation croisée (StratifiedKFold).

4.1 Résultats comparatifs

Logistic Regression : faible performance (~0.60 accuracy).
Random Forest : très performant (~0.92 accuracy).
Gradient Boosting : performant et stable (~0.92 accuracy).

5. Sélection du modèle final

Modèle retenu : Gradient Boosting Classifier.

5.1 Performances

Validation : Accuracy 0.927, F1 0.845
Test : Accuracy 0.9226, F1 0.8446
Recall élevé → bonne détection des défauts

5.2 Sauvegarde

Pipeline sauvegardé : GradientBoostingClassifier_LOANS_STATUS.pkl

Conclusion

Pipeline complet et robuste avec bonnes performances (~92% accuracy). Gradient Boosting est le modèle final retenu pour production.